

Predecir Especies de Pingüinos con Machine Learning

Ximena Pérez Escalante

A01751827

Instituto Tecnológico y de Estudios Superiores de Monterrey

Agosto 2026

Abstract La identificación de especies de pingüinos a partir de sus características físicas es una aplicación práctica de machine learning para analizar y clasificar los datos. Este trabajo desarrolla un modelo de clasificación de regresión logística para predecir la especie de los pingüinos a partir de medidas físicas, tales como la longitud y profundidad del pico, la longitud de la aleta y la masa corporal. Los datos fueron preprocesados y utilizados para entrenar el modelo, permitiendo identificar relaciones entre las características físicas de los pingüinos y su especie correspondiente. El modelo resultante logró un ajuste adecuado al conjunto de datos, demostrando que la regresión logística puede establecer eficazmente patrones de clasificación a partir de medidas morfológicas. Este estudio destaca la aplicación de técnicas de aprendizaje supervisado a conjuntos de datos biológicos y demuestra cómo los atributos físicos pueden utilizarse para facilitar la identificación automatizada de especies.

Keywords (palabras clave): Regresión logística, Clasificación, Pingüinos, Machine Learning.

Introducción

Los pingüinos, cuyo nombre científico es Spheniscidae, son aves marinas, no voladoras. Su distribución geográfica se centra en el Hemisferio Sur (a excepción del pingüino de las islas Galápagos). Se dividen en 18 especies

diferentes, de las cuales se hablará de tres diferentes: Adelia, Barbijo y Gentoo.



Figura 1: Pingüino de Adelia




Figura 2: Pingüino Barbijo




Figura 3: Pingüino Gentoo

La clasificación de especies mediante técnicas de aprendizaje automático permite identificar patrones en los datos y utilizarlos para realizar predicciones. En el caso de los pingüinos,

características físicas como la longitud del pico, la profundidad del pico, la longitud de las aletas y el peso pueden proporcionar información relevante para diferenciar entre especies. Por ello, desarrollar un modelo de clasificación basado en estas características permite analizar la relación entre sus rasgos físicos y su especie, además de demostrar cómo los modelos de aprendizaje automático pueden utilizar datos biológicos para realizar predicciones de manera eficiente.

Descripción del Dataset

Se utilizó el Dataset “Penguin Species Dataset”. El cual es un Dataset sintético que contiene datos sobre el físico de los pingüinos de tres especies diferentes: Adelie, Chinstrap y Gentoo. Así como dos datos categóricos. Está compuesto por 1000 instancias y 6 features descritas en la siguiente tabla:

Nombre	Significado	Tipo de dato
island	Isla asociada al pingüino (Torgersen, Biscoe, Dream)	String
culmen_length_mm	Longitud del culmen (bill) del pingüino en milímetros.	Decimal
culmen_depth_mm	Profundidad del culmen en milímetros	Decimal
flipper_length_mm	Longitud de las aletas del pingüino en milímetros	Decimal

body_mass_g	Masa corporal del pingüino en gramos	Decimal
sex	Sexo del pingüino (Male, Female)	String

Tabla 1: Descripción de Features del Dataset




Figura 4: Anatomía del pingüino

Donde la variable que se busca predecir es la siguiente:

Nombre	Significado	Tipo de dato
species	Especie del pingüino (Adelie, Chinstrap, Gentoo)	String

Tabla 2: Descripción de la variable a predecir del Dataset

En Machine Learning los datos se representan en dos tipos:

- **Númericos:** culmen_length_mm, culmen_depth_mm, flipper_length_mm, body_mass_g.
- **Catégoricos:** species, island y sex.

En el caso del Dataset, únicamente hay datos numéricos continuos.

ETL

ETL, por sus siglas en inglés se refiere al proceso: *Extract - Transform - Load*.

Extracción

En esta etapa se extraen los datos que se usarán para el modelo. Para ello se obtuvo el Dataset, presentado en la sección anterior, de la plataforma Kaggle y se importó en Python.

Transformación

Datos nulos

Se comenzó revisando si el Dataset tiene datos nulos y se obtuvieron los siguientes resultados:

Columna	Número de datos nulos
species	0
island	0
culmen_length_mm	10
culmen_depth_mm	10
flipper_length_mm	10
body_mass_g	10
sex	10

Tabla 3: Cantidad de datos nulos por columna

En total, hay 50 datos nulos, pero antes de tomar una decisión sobre cómo tratarlos, es necesario saber qué tipo de caso está presente en el Dataset:

- Fully missing I
- Fully missing II
- Partially missing

Para ello, se desplegaron todas las filas que contienen datos nulos en al menos una columna. Al hacer esto, se obtuvo un total de 49 filas (4.9% del total de los datos):

	species	island	culmen length mm	culmen depth mm	flipper length mm	body mass g	sex
36	Adelie	Torgersen	39.6	17.5	NaN	3605	Male
38	Chinstrap	Dream	47.4	16.2	185	3958	NaN
42	Adelie	Dream	NaN	18.9	187	3567	Male
51	Gentoo	Biscoe	47.2	16.4	NaN	4792	Female
149	Adelie	Torgersen	38.3	18.7	195	NaN	Male
150	Gentoo	Biscoe	45.9	NaN	218	4541	Male
154	Gentoo	Biscoe	46.2	14.6	221	4848	NaN
160	Adelie	Dream	38.2	NaN	195	3677	Female
170	Chinstrap	Dream	45.8	19.4	205	3695	NaN
192	Gentoo	Biscoe	47.6	16.4	213	NaN	Male
202	Adelie	Torgersen	38.3	17.6	NaN	3833	Female
205	Adelie	Dream	38.5	NaN	187	3728	Male
222	Adelie	Dream	41.2	20.3	183	NaN	Male
287	Chinstrap	Dream	41	NaN	199	3851	Male
296	Gentoo	Biscoe	49.1	15.7	NaN	5858	Female
353	Adelie	Dream	NaN	19.1	191	4123	Male
360	Adelie	Torgersen	NaN	19.2	191	3866	Male
362	Chinstrap	Dream	51.3	17.3	NaN	3918	Female
363	Chinstrap	Dream	46	19.7	193	NaN	Male
378	Gentoo	Biscoe	42.5	15.4	218	NaN	Female
403	Gentoo	Biscoe	50	15	NaN	4720	Female
501	Chinstrap	Dream	43.8	17.5	194	NaN	Male
535	Gentoo	Biscoe	47.7	14.7	212	5022	NaN
559	Chinstrap	Dream	48.2	20	NaN	4045	Male
563	Adelie	Torgersen	40.9	18.1	196	4136	NaN
581	Gentoo	Biscoe	NaN	15.2	212	5194	Male
597	Adelie	Dream	37.8	NaN	189	3879	Male
638	Adelie	Dream	38	NaN	190	3548	Female
664	Adelie	Dream	43.2	20.6	NaN	3599	Female
667	Adelie	Dream	NaN	19.8	192	4110	NaN
678	Gentoo	Biscoe	47.1	NaN	214	4896	Female
697	Chinstrap	Dream	44.6	NaN	198	3681	Male
705	Gentoo	Biscoe	45.8	NaN	224	4927	Female
710	Gentoo	Biscoe	50.8	13.6	221	5679	NaN
714	Adelie	Torgersen	40.2	18.7	195	NaN	Male
725	Gentoo	Biscoe	NaN	14.9	224	5165	Female
729	Adelie	Torgersen	39.7	18.1	NaN	3952	Male
742	Gentoo	Biscoe	NaN	15	215	5516	Female
746	Adelie	Dream	40.1	17.9	186	4284	NaN
748	Gentoo	Biscoe	NaN	14.7	216	6237	Male
775	Adelie	Torgersen	NaN	18	194	3505	Male
788	Chinstrap	Dream	NaN	20.7	200	3775	Female
823	Adelie	Torgersen	33.4	16.6	179	4014	NaN
838	Chinstrap	Dream	50.9	19.5	199	4048	NaN
857	Chinstrap	Dream	55.9	NaN	204	3578	Female
885	Adelie	Torgersen	40.2	18.7	191	NaN	Female
908	Adelie	Dream	37.6	18.7	192	NaN	Male
958	Adelie	Dream	41.6	20.2	183	NaN	Female
977	Adelie	Dream	40.4	17.8	NaN	3402	Male

Tabla 4: Filas con datos nulos.

Las celdas en rojo representan los datos nulos y a simple vista se puede interpretar fácilmente que el caso es “Partially missing”. Ya que los datos faltantes se encuentran distribuidos aleatoriamente a lo largo de las cinco columnas.

Al ser un porcentaje de instancias muy bajo, se podrían eliminar las 49 filas, sin embargo, para conservarlos se imputarán.

Antes de realizar la imputación, se visualizaron las variables numéricas en histogramas, dos por cada especie para tener la

división entre hembra y macho. Esto con el fin de entender la distribución de los datos para saber con qué valor es más conveniente imputarlos.

A continuación se muestran los valores de estas variables en histogramas, donde los cuatro de la izquierda corresponden a las hembras y los de la derecha a los machos.

Adelia




Figura 5: Histogramas de variables numéricas del pingüino de Adelia hembra.

Figura 6: Histogramas de variables numéricas del pingüino de Adelia macho.

	culmen_length_mm	culmen_depth_mm	flipper_length_mm	body_mass_g
count	230	228	228	228
mean	38.703	18.326	189.61	3671.6
std	2.2987	1.0171	5.8858	280.64
min	32.4	15.7	176	2943
25%	37.3	17.6	185	3467.2
50%	38.6	18.3	189	3682
75%	40.175	19	194	3849.7
max	44.8	20.8	205	4550

Tabla 5: Estadística descriptiva del pingüino de Adelia hembra.

	culmen _length _mm	culmen _depth_ mm	flipper_ length_ mm	body_m ass_g
count	223	225	224	223
mean	39.041	18.233	190.12	3731.6
std	2.1005	0.9716	4.9193	306.65
min	33.5	15.6	175	2830
25%	37.7	17.6	187	3535.5
50%	39	18.2	190	3757
75%	40.5	18.9	193	3942
max	44.6	21.4	202	4519

Tabla 6: Estadística descriptiva del pingüino de Adelia macho.

	culmen _length _mm	culmen _depth_ mm	flipper_ length_ mm	body_ mass_g
count	117	117	117	118
mean	48.982	18.256	194.93	3733.1
std	2.8886	0.8281	6.7552	316.68
min	40.9	16.2	178	2880
25%	47	17.7	191	3535
50%	49	18.2	195	3747.5
75%	51	18.8	200	3973
max	55.9	20.7	213	4379

Tabla 7: Estadística descriptiva del pingüino Barbijo hembra.

Barbijo




Figura 7: Histogramas de variables numéricas del pingüino Barbijo hembra.

Figura 8: Histogramas de variables numéricas del pingüino Barbijo macho.

	culmen _length _mm	culmen _depth_ mm	flipper_ length_ mm	body_ mass_g
count	130	128	129	128
mean	48.645	18.422	196.27	3730.8
std	2.9348	0.9702	7.1771	310.58
min	41	15.8	175	2879
25%	46.2	17.775	192	3519.7
50%	48.35	18.4	196	3765.5
75%	50.8	19.125	201	3960.2
max	56	20.9	214	4591

Tabla 8: Estadística descriptiva del pingüino Barbijo macho.

Gentoo




Figura 9: Histogramas de variables numéricas del pingüino Gentoo hembra.

Figura 10: Histogramas de variables numéricas del pingüino Gentoo macho.

	culmen_length_mm	culmen_depth_mm	flipper_length_mm	body_mass_g
count	112	112	111	113
mean	47.421	14.883	217.18	5080.3
std	2.9995	0.8209	5.5908	452.36
min	39.8	13	205	3829
25%	45.55	14.275	214	4792
50%	47.25	15	216	5046
75%	49.5	15.4	220	5354
max	54	17.1	235	6258

Tabla 9: Estadística descriptiva del pingüino Gentoo hembra.

	culmen_length_mm	culmen_depth_mm	flipper_length_mm	body_mass_g
count	169	170	171	170
mean	47.350	14.999	217.44	5041.6
std	3.0217	0.7946	5.7210	470.97
min	38.2	13	201	3623
25%	45.4	14.4	213	4712.5
50%	47.7	15	218	5032.5
75%	49.5	15.6	222	5282.7
max	53.8	17.2	231	6317

Tabla 10: Estadística descriptiva del pingüino Gentoo macho.

Tras comparar la diferencia de la estadística descriptiva de cada especie por sexo, se tomó la decisión de usar la mediana de cada variable para imputar los datos faltantes. Ya que aunque

no cambia significativamente con respecto al promedio, es el valor indicado, ya que como lo mostraron los histogramas, ninguna distribución es normal como tal.

Para las instancias cuyo valor faltante es el sexo del pingüino, se tomó la decisión de imputarlas con el valor 'Unknown'. Ya que son únicamente el 1% de todo el Dataset, esto puede ayudar en los casos reales donde no se conozca el sexo del pingüino y procura conservar la mayor cantidad de información.

Tratamiento de variables categóricas

En Machine Learning, las variables categóricas deben convertirse en variables numéricas para que el modelo de regresión logística pueda ser entrenado de manera correcta. Porque este mismo no puede procesar strings.

One-hot encoding

Consiste en crear una columna por cada categoría, en las cuales se almacenan valores binarios. Donde 1 significa que la instancia corresponde a esa categoría y 0 que no.

Island

Se crearon las siguientes columnas:

- island_Biscoe
- island_Dream
- island_Torgersen

Sex

Se crearon las siguientes columnas:

- sex_Male
- sex_Female

- sex_Unknown

Label encoding

Asigna un número entero a cada categoría que va de 0 a n - 1.

Species

Al tratarse de la variable que se busca predecir, o label como su nombre lo indica, se utiliza esta técnica. La transformación arrojó los siguientes resultados:

Especie	Label encoded
Adelie	0
Chinstrap	1
Gentoo	2

Tabla 11: Resultados de label encoding en la clase Species.

Como hay un total de tres clases, el rango va de 0 a 2.

Dividir datos en train, validation y test

Antes de realizar la división de los datos, se realizó un shuffle para asegurar que estos estén acomodados de manera aleatoria. Se usó sklearn para dividirlos en el siguiente porcentaje:

Train: 70%

Validation: 15%

Test: 15%

La razón por la que se eligieron estos porcentajes es para conservar la mayoría de los datos en train y que validation o test no queden

con un bajo porcentaje de datos con respecto al otro. Esto con el fin de poder realizar una mejor comparativa de los resultados.

Escalamiento de los datos

Para que los datos se encuentren en un rango similar, se utilizó la estandarización, cuya fórmula es la siguiente:

$$X_{estandarizada} = \frac{X - \text{promedio}(X)}{\text{std}(X)}$$

Esto se debe a que en modelos de regresión, ya sea lineal o logística se usa este método. Lo que hace es escalar los features para que el promedio sea igual a cero y la desviación estándar igual a uno.

Por último, para finalizar con esta fase, se confirmó que no había presencia de datos duplicados.

Carga de datos (Loading)

En esta fase únicamente se carga el Dataset con las modificaciones realizadas en la fase de transformación.

Modelo de Regresión Logística

En Machine Learning, para los problemas de clasificación, se utiliza la regresión logística porque predice categorías al tener un output de la probabilidad de que la instancia pertenezca a x clase.

Función de hipótesis

A comparación de la regresión lineal, en este caso la función que se utiliza es la sigmoide:

$$f(z) = \frac{1}{1+e^{-z}}$$

La razón por la que se utiliza es que mapea cualquier valor a un número entre 0 y 1, ideal para problemas de clasificación.

Función de costo

Se utiliza cross entropy, dada por la siguiente ecuación:

$$-(y) * \log(\hat{y}) - (y - 1) * \log(1 - \hat{y})$$

Compara las etiquetas reales con las predichas y penaliza demasiado los errores al hacer que la pérdida aumente considerablemente cuando estos suceden.

Función de optimización

Para optimizar, de igual manera se utiliza gradiente descendiente:

$$\theta_j = \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

Donde θ = parámetros a optimizar;

α = tasa de aprendizaje; J = función de costo.

Su función es minimizar el error del modelo actualizando los parámetros en dirección de la descendencia de la pérdida.

Resultados

Tras entrenar el modelo, se obtuvo el valor de las siguientes métricas:

- *Accuracy*: proporción de predicciones correctas sobre el total de predicciones realizadas por el modelo y va del 0 al 1.
- *Precision*: indica cuántas de las predicciones "positivas" fueron realmente correctas.
- *Recall*: indica la proporción de verdaderos positivos detectados con respecto al total de casos positivos reales.
- *F-Score*: combina la precisión y la exhaustividad en una única métrica para equilibrar la relación de compromiso entre ambas.
- *Support*: número de ocurrencias reales de una clase específica en las etiquetas verdaderas de su conjunto de datos.

Asimismo, se obtiene la matriz de confusión, la cual se usa para medir el desempeño de un modelo de clasificación. Lo logra comparando los resultados de las predicciones contra los valores reales, para entender en dónde se está equivocando el modelo. Las predicciones se dividen en las siguientes categorías:

- True Positive (TP).
- True Negative (TN).
- False Positive (FP).
- False Negative (FN).

Train

Accuracy: 0.9928

Error: 0.02989

Clase	Precision	Recall	f1-score	Support
0	0.99	0.99	0.99	319
1	0.99	0.98	0.99	178
2	1.0	1.0	1.0	203

Tabla 12: Métricas por clase de train.

	Precision	Recall	f1-score	Support
accuracy			0.99	700
Macro avg	0.99	0.99	0.99	700
Weighted avg	0.99	0.99	0.99	700

Tabla 13: Métricas generales de train.

Matriz de confusión




Figura 11: Matriz de confusión: train.

Validation

Accuracy: 0.9933

Error: 0.04121

Clase	Precision	Recall	f1-score	Support
0	0.99	1.0	0.99	70
1	1.0	0.97	0.99	34
2	1.0	1.0	1.0	46

Tabla 14: Métricas por clase de validation.

	Precision	Recall	f1-score	Support
accuracy			0.99	150
Macro avg	1.0	0.99	0.99	150
Weighted avg	0.99	0.99	0.99	150

Tabla 15: Métricas generales de validation.




Figura 12: Matriz de confusión: validation.

Test

Accuracy: 1.0

Error: 0.0154

Clase	Precision	Recall	f1-score	Support
0	1.0	1.0	1.0	72
1	1.0	1.0	1.0	39
2	1.0	1.0	1.0	39

Tabla 16: Métricas por clase de test.

	Precision	Recall	f1-score	Support
accuracy			1.0	150
Macro avg	1.0	1.0	1.0	150
Weighted avg	1.0	1.0	1.0	150

Tabla 17: Métricas generales de test.




Figura 13: Matriz de confusión: test.

Diagnóstico

Bias

Para saberlo, es necesario observar el valor de la pérdida en la etapa de entrenamiento (0.02989).

Varianza

Para obtenerla se debe obtener la diferencia entre la pérdida de train con respecto a la de validation y test respectivamente.

Train y val: $0.04121 - 0.02989 = 0.01132$

Train y test: $0.0154 - 0.02989 = -0.01449$

Conclusión

Después de observar detalladamente los valores tanto de bias como de la varianza, se puede concluir que el modelo no cae ni en underfitting ni en overfitting, ya que ambos valores son bajos, lo cual indica que se encuentra en un punto de medio de convergencia de ambos valores.

Bibliografía

Srisyra02. (s. f.). *Penguin species dataset*.

Kaggle.

<https://www.kaggle.com/datasets/srisyra02/penguin-species-dataset>

PNGTree. (s. f.). *Diagram showing parts of penguin flipper, bill [Ilustración]*. [PNGTree](#)

National Geographic España. (s. f.).

Pingüinos. [National Geographic España](#)

Instagram. (s. f.). *Publicación de Instagram [Fotografía]*. [Instagram](#)

Global Penguin Society. (s. f.). *Pingüino*

Gentoo o Papúa (Pygoscelis papua). [Global Penguin Society](#)