

Predecir Especies de Pingüinos con Machine Learning

Ximena Pérez Escalante

A01751827

Instituto Tecnológico y de Estudios Superiores de Monterrey

Agosto 2026

Resumen/Abstract ... *Keywords (palabras clave): Regresión logística, Clasificación, Pingüinos.*

Introducción

Los pingüinos, cuyo nombre científico es Spheniscidae, son aves marinas, no voladoras.

Su distribución geográfica se centra en el Hemisferio Sur (a excepción del pingüino de las islas Galápagos). Se dividen en 18 especies diferentes, de las cuales se hablará de tres diferentes: Adelia, Barbijo y Gentoo.



Figura 1: Pingüino de Adelia

Pingüino de Adelia

Su nombre científico es *Pygoscelis adeliae*.

<https://www-nationalgeographic-com.tr/anslate.google/animals/birds/facts/adelie-penguin? x tr sl=en& x tr tl=es& x tr hl=es& x tr pto=tc>

Pingüino Barbijo




Figura 2: Pingüino Barbijo

Pingüino Gentoo




Figura 3: Pingüino Gentoo




Figura 4: Anatomía del pingüino

Descripción del Dataset

Se utilizó el Dataset “Penguin Species Dataset”. El cual es un Dataset sintético que contiene datos sobre el físico de los pingüinos de tres especies diferentes: Adelie, Chinstrap y Gentoo. Así como dos datos categóricos. Está compuesto por 1000 instancias y 6 features descritas en la siguiente tabla:

Nombre	Significado	Tipo de dato
island	Isla asociada al pingüino (Torgersen, Biscoe, Dream)	String
culmen_length_mm	Longitud del culmen (bill) del pingüino en milímetros.	Decimal
culmen_depth_mm	Profundidad del culmen en milímetros	Decimal
flipper_length_mm	Longitud de las aletas del pingüino en milímetros	Decimal
body_mass_g	Masa corporal del pingüino en gramos	Decimal
sex	Sexo del pingüino (Male, Female)	String

Tabla 1: Descripción de Features del Dataset

Donde la variable que se busca predecir es la siguiente:

Nombre	Significado	Tipo de dato
species	Especie del pingüino (Adelie, Chinstrap, Gentoo)	String

Tabla 2: Descripción de la variable a predecir del Dataset

En Machine Learning los datos se representan en dos tipos:

- *Númericos*: culmen_length_mm, culmen_depth_mm, flipper_length_mm, body_mass_g.
- *Catégoricos*: species, island y sex.

En el caso del Dataset, únicamente hay datos numéricos continuos.

ETL

ETL, por sus siglas en inglés se refiere al proceso: *Extract - Transform - Load*.

Extracción

En esta etapa se extraen los datos que se usarán para el modelo. Para ello se obtuvo el Dataset, presentado en la

sección anterior, de la plataforma Kaggle y se importó en Python.

Transformación

Datos nulos

Se comenzó revisando si el Dataset tiene datos nulos y se obtuvieron los siguientes resultados:

Columna	Número de datos nulos
species	0
island	0
culmen_length_mm	10
culmen_depth_mm	10
flipper_length_mm	10
body_mass_g	10
sex	10

Tabla 3: Cantidad de datos nulos por columna

En total, hay 50 datos nulos, pero antes de tomar una decisión sobre cómo tratarlos, es necesario saber qué tipo de caso está presente en el Dataset:

- Fully missing I
- Fully missing II
- Partially missing

Para ello, se desplegaron todas las filas que contienen datos nulos en al menos una columna. Al hacer esto, se obtuvo un total de 49 filas (4.9% del total de los datos):

	species	island	culmen_length_mm	culmen_depth_mm	flipper_length_mm	body_mass_g	sex
36	Adelie	Torgersen	39.6	17.5	NaN	3605	Male
38	Chinstrap	Dream	47.4	16.2	185	3958	NaN
42	Adelie	Dream	NaN	18.9	187	3567	Male
51	Gentoo	Biscoe	47.2	16.4	NaN	4792	Female
149	Adelie	Torgersen	38.3	18.7	195	NaN	Male
150	Gentoo	Biscoe	45.9	NaN	218	4541	Male
154	Gentoo	Biscoe	46.2	14.6	221	4848	NaN
160	Adelie	Dream	38.2	NaN	195	3677	Female
170	Chinstrap	Dream	45.8	19.4	205	3695	NaN
192	Gentoo	Biscoe	47.6	16.4	213	NaN	Male
202	Adelie	Torgersen	38.3	17.6	NaN	3833	Female
205	Adelie	Dream	38.5	NaN	187	3728	Male
222	Adelie	Dream	41.2	20.3	183	NaN	Male
287	Chinstrap	Dream	41	NaN	199	3851	Male
296	Gentoo	Biscoe	49.1	15.7	NaN	5858	Female
353	Adelie	Dream	NaN	19.1	191	4123	Male
360	Adelie	Torgersen	NaN	19.2	191	3866	Male
362	Chinstrap	Dream	51.3	17.3	NaN	3918	Female
363	Chinstrap	Dream	46	19.7	193	NaN	Male
378	Gentoo	Biscoe	42.5	15.4	218	NaN	Female
403	Gentoo	Biscoe	50	15	NaN	4720	Female
501	Chinstrap	Dream	43.8	17.5	194	NaN	Male
535	Gentoo	Biscoe	47.7	14.7	212	5022	NaN
559	Chinstrap	Dream	48.2	20	NaN	4045	Male
563	Adelie	Torgersen	40.9	18.1	196	4136	NaN
581	Gentoo	Biscoe	NaN	15.2	212	5194	Male
597	Adelie	Dream	37.8	NaN	189	3879	Male
638	Adelie	Dream	38	NaN	190	3548	Female
664	Adelie	Dream	43.2	20.6	NaN	3599	Female
667	Adelie	Dream	NaN	19.8	192	4110	NaN
678	Gentoo	Biscoe	47.1	NaN	214	4896	Female
697	Chinstrap	Dream	44.6	NaN	198	3681	Male
705	Gentoo	Biscoe	45.8	NaN	224	4927	Female
710	Gentoo	Biscoe	50.8	13.6	221	5679	NaN
714	Adelie	Torgersen	40.2	18.7	195	NaN	Male
725	Gentoo	Biscoe	NaN	14.9	224	5165	Female
729	Adelie	Torgersen	39.7	18.1	NaN	3952	Male
742	Gentoo	Biscoe	NaN	15	215	5516	Female
746	Adelie	Dream	40.1	17.9	186	4284	NaN
748	Gentoo	Biscoe	NaN	14.7	216	6237	Male
775	Adelie	Torgersen	NaN	18	194	3505	Male
788	Chinstrap	Dream	NaN	20.7	200	3775	Female
823	Adelie	Torgersen	33.4	16.6	179	4014	NaN
838	Chinstrap	Dream	50.9	19.5	199	4048	NaN
857	Chinstrap	Dream	55.9	NaN	204	3578	Female
885	Adelie	Torgersen	40.2	18.7	191	NaN	Female
908	Adelie	Dream	37.6	18.7	192	NaN	Male
958	Adelie	Dream	41.6	20.2	183	NaN	Female
977	Adelie	Dream	40.4	17.8	NaN	3402	Male

Tabla 4: Filas con datos nulos.

Las celdas en rojo representan los datos nulos y a simple vista se puede interpretar fácilmente que el caso es “Partially missing”. Ya que los datos faltantes se encuentran distribuidos aleatoriamente a lo largo de las cinco columnas.

Al ser un porcentaje de instancias muy bajo, se podrían eliminar las 49 filas, sin embargo, para conservarlos se imputarán.

Antes de realizar la imputación, se visualizaron las variables numéricas en histogramas, dos por cada especie para tener la división entre hembra y macho.

Esto con el fin de entender la distribución de los datos para saber con qué valor es más conveniente imputarlos.

Adelia




Figura 5: Histogramas de variables numéricas del pingüino de Adelia hembra.

	culmen_length_mm	culmen_depth_mm	flipper_length_mm	body_mass_g
count	230	228	228	228
mean	38.703	18.326	189.61	3671.6
std	2.2987	1.0171	5.8858	280.64
min	32.4	15.7	176	2943
25%	37.3	17.6	185	3467.2
50%	38.6	18.3	189	3682
75%	40.175	19	194	3849.7
max	44.8	20.8	205	4550

Tabla 5: Filas con datos nulos.




Figura 6: Histogramas de variables numéricas del pingüino de Adelia macho.




Figura 7: Histogramas de variables numéricas del pingüino Barbijo hembra.

	culmen_length_mm	culmen_depth_mm	flipper_length_mm	body_mass_g
count	223	225	224	223
mean	39.041	18.233	190.12	3731.6
std	2.1005	0.9716	4.9193	306.65
min	33.5	15.6	175	2830
25%	37.7	17.6	187	3535.5
50%	39	18.2	190	3757
75%	40.5	18.9	193	3942
max	44.6	21.4	202	4519

Tabla 6: Filas con datos nulos

	culmen_length_mm	culmen_depth_mm	flipper_length_mm	body_mass_g
count	117	117	117	118
mean	48.982	18.256	194.93	3733.1
std	2.8886	0.8281	6.7552	316.68
min	40.9	16.2	178	2880
25%	47	17.7	191	3535
50%	49	18.2	195	3747.5
75%	51	18.8	200	3973
max	55.9	20.7	213	4379

Tabla 7: Filas con datos nulos

Barbijo




Figura 8: Histogramas de variables numéricas del pingüino Barbijo macho.

	culmen_length_mm	culmen_depth_mm	flipper_length_mm	body_mass_g
count	130	128	129	128
mean	48.645	18.422	196.27	3730.8
std	2.9348	0.9702	7.1771	310.58
min	41	15.8	175	2879
25%	46.2	17.775	192	3519.7
50%	48.35	18.4	196	3765.5
75%	50.8	19.125	201	3960.2
max	56	20.9	214	4591

Tabla 8: Filas con datos nulos

Gentoo




Figura 9: Histogramas de variables numéricas del pingüino Gentoo hembra.

	culmen_length_mm	culmen_depth_mm	flipper_length_mm	body_mass_g
count	112	112	111	113
mean	47.421	14.883	217.18	5080.3
std	2.9995	0.8209	5.5908	452.36
min	39.8	13	205	3829
25%	45.55	14.275	214	4792
50%	47.25	15	216	5046
75%	49.5	15.4	220	5354
max	54	17.1	235	6258

Tabla 9: Filas con datos nulos




Figura 10: Histogramas de variables numéricas del pingüino Gentoo macho.

	culmen _length _mm	culme n_dept h_mm	flipper _length _mm	body_ mass_ g
count	169	170	171	170
mean	47.350	14.999	217.44	5041.6
std	3.0217	0.7946	5.7210	470.97
min	38.2	13	201	3623
25%	45.4	14.4	213	4712.5
50%	47.7	15	218	5032.5
75%	49.5	15.6	222	5282.7
max	53.8	17.2	231	6317

Tabla 9: Filas con datos nulos

Tras comparar la diferencia de la estadística descriptiva de cada especie por sexo, se tomó la decisión de usar la mediana de cada variable para imputar los datos faltantes. Ya que aunque no cambia significativamente con respecto al promedio, es el valor indicado, ya que como lo mostraron los histogramas, ninguna distribución era normal como tal.

Para las instancias cuyo valor faltante es el sexo del pingüino, se tomó la decisión de eliminarlas por completo. Ya que son únicamente el 1% de todo el Dataset y esto es una decisión que procura conservar la información lo más limpia posible.

Tratamiento de variables categóricas

En Machine Learning, las variables categóricas deben convertirse en variables numéricas para que el modelo de regresión logística pueda ser entrenado de manera correcta. Porque este mismo no puede procesar strings.

One-hot encoding

Consiste en crear una columna por cada categoría, en las cuales se almacenan valores binarios. Donde 1 significa que la instancia corresponde a esa categoría y 0 que no.

Island

Se crearon las siguientes columnas:

- island_Biscoe
- island_Dream
- island_Torgersen

Label encoding

Asigna un número entero a cada categoría que va de 0 a n - 1.

Species

Al tratarse de la variable que se busca predecir, o label como su nombre lo indica, se utiliza esta técnica. La transformación arrojó los siguientes resultados:

Especie	Label encoded
Adelie	0
Chinstrap	1
Gentoo	2

Sex

Debido a que únicamente hay dos categorías en esta variable, de igual manera se utiliza label encoding para que los valores de esta columna tengan valores binarios como se muestra en la siguiente tabla:

Sexo	Label encoded
Male	0
Female	1

Dividir datos en train, validation y test

Antes de realizar la división de los datos, se realizó un shuffle para asegurar que estos estén acomodados de manera aleatoria. Se usó sklearn para dividirlos en el siguiente porcentaje:

Train: 70%

Validation: 15%

Test: 15%

Escalamiento de los datos

Para que los datos se encuentren en un rango similar, se utilizó la estandarización, cuya fórmula es la siguiente:

$$X_{estandarizada} = \frac{X - \text{promedio}(X)}{\text{std}(X)}$$

Esto se debe a que en modelos de regresión, ya sea lineal o logística se usa este método.

Carga de datos (Loading)

En esta fase únicamente se carga el Dataset con las modificaciones realizadas en la fase de transformación.

Modelo de Regresión Logística

En Machine Learning, para los problemas de clasificación, se utiliza la regresión logística.

Función de hipótesis

A comparación de la regresión lineal, en este caso la función que se utiliza es la sigmoide:

$$f(z) = \frac{1}{1+e^{-z}}$$

La razón por la que se utiliza es que mapea cualquier valor a un número entre 0 y 1, ideal para problemas de clasificación.

Función de costo

Se utiliza cross entropy, dado por la siguiente ecuación:

$$-(y) * \log(\hat{y}) - (y - 1) * \log(1 - \hat{y})$$

[Más explicación]

Función de optimización

Para optimizar, de igual manera se utiliza gradiente descendiente:

$$\theta_j = \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

Donde θ = parámetros a optimizar;
 α = tasa de aprendizaje; J = función de costo.

[Más explicación]

Resultados

Tras entrenar el modelo, se obtuvieron los siguientes resultados. Donde se muestra el valor de accuracy, la cual representa...


La matriz de confusión se usa para...

[Explicar]

Validation

Accuracy: 0.98

Matriz de confusión



Test



Accuracy: 1.0

Matriz de confusión

Bibliografía

<https://www.kaggle.com/datasets/srisyra02/penguin-species-dataset>

[1,200 × 1,1181,200 × 1,118](#)

<https://www.nationalgeographic.com.es/animales/pinguinos>

[1,440 × 1,8001,440 × 1,800](#)

[5,411 × 3,6125,411 × 3,612](#)